

#### **XML to Graph Mapping Tool**

Bachelorarbeit Präsentation

**Safwat Zakkor** 

217205264

Betreuer:

**Dr.Holger Meyer** 

Holger Meyer (PhD), U of Rostock, CSEE, Database Research Group



### Inhalt

DATUM UND UHRZEIT: 29. MÄRZ.2022, 15:00 UHR

Via Zoom

1

#### Einleitung

• Was ist das Ziel dieser Arbeit



#### Ergebnisse

• Ausgabe des generierten Graphen



#### Übersicht

- Allgemeine Übersicht
- Motivation
- Modulstruktur



#### **Filter**

- Die verschiedenen Varianten von XML-Dokumente
- Beispiele XML
- XML-Schema
- XPath in XML-Dokumente Funktionsweise



#### **Graph Generator**

- Generator
- Schritt für Schritt wie ein Graph erstellen wird
- Match (Find)
- CreateNode
- CreateEdge
- Node replacement cases
  - -Problemdarstellung
  - -Lösungsvarianten
  - -Beispiele



#### Exporter

- Die Formate
- Exporter als
  - -Node.csv
  - -Edge.csv
- Andere Vorschläge
  - -Gexf
  - -Graphml



#### Zusammenfassung und Ausblick

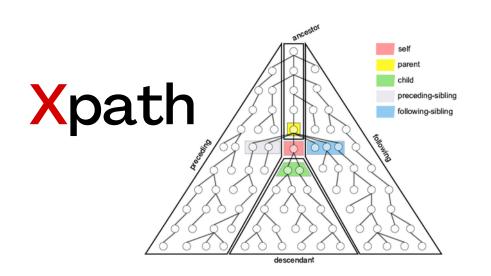
- Was wurde geschafft? 🗸
- Welche Teile wurden implementiert?
- Teile die nicht gemacht wurden? (...)
- Erweiterungen
- Ausgabeformat

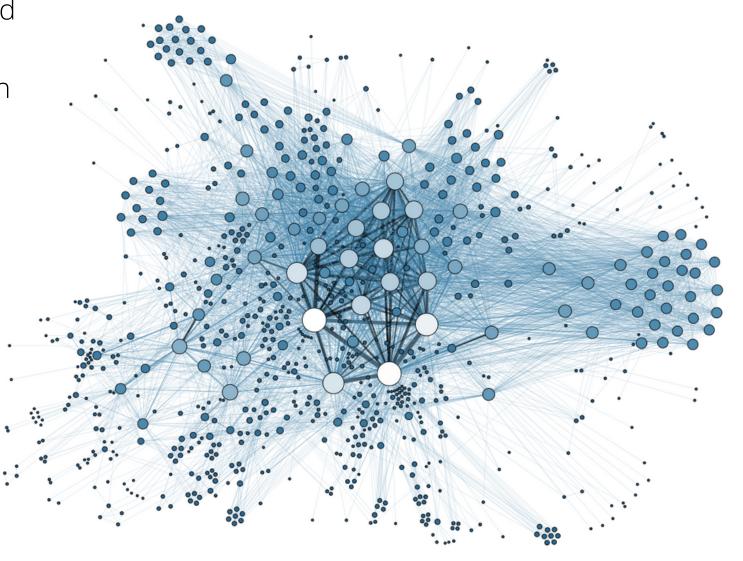


### Das Ziel

- Entwicklung und Konzeption einer Anwendung zur Ermöglichung einer Analyse und Visualisierung für XML-Dokumenten in Property Graph model
- Prototypische Implementierung und qualitätsbasierte Evaluierung anhand von ISEBEL-Beispielszenarien
- Die Transformation sollte von benutzerdefinierten Regeln geleitet werden
- Ausgabe des generierten Graphen in verschiedenen Formaten







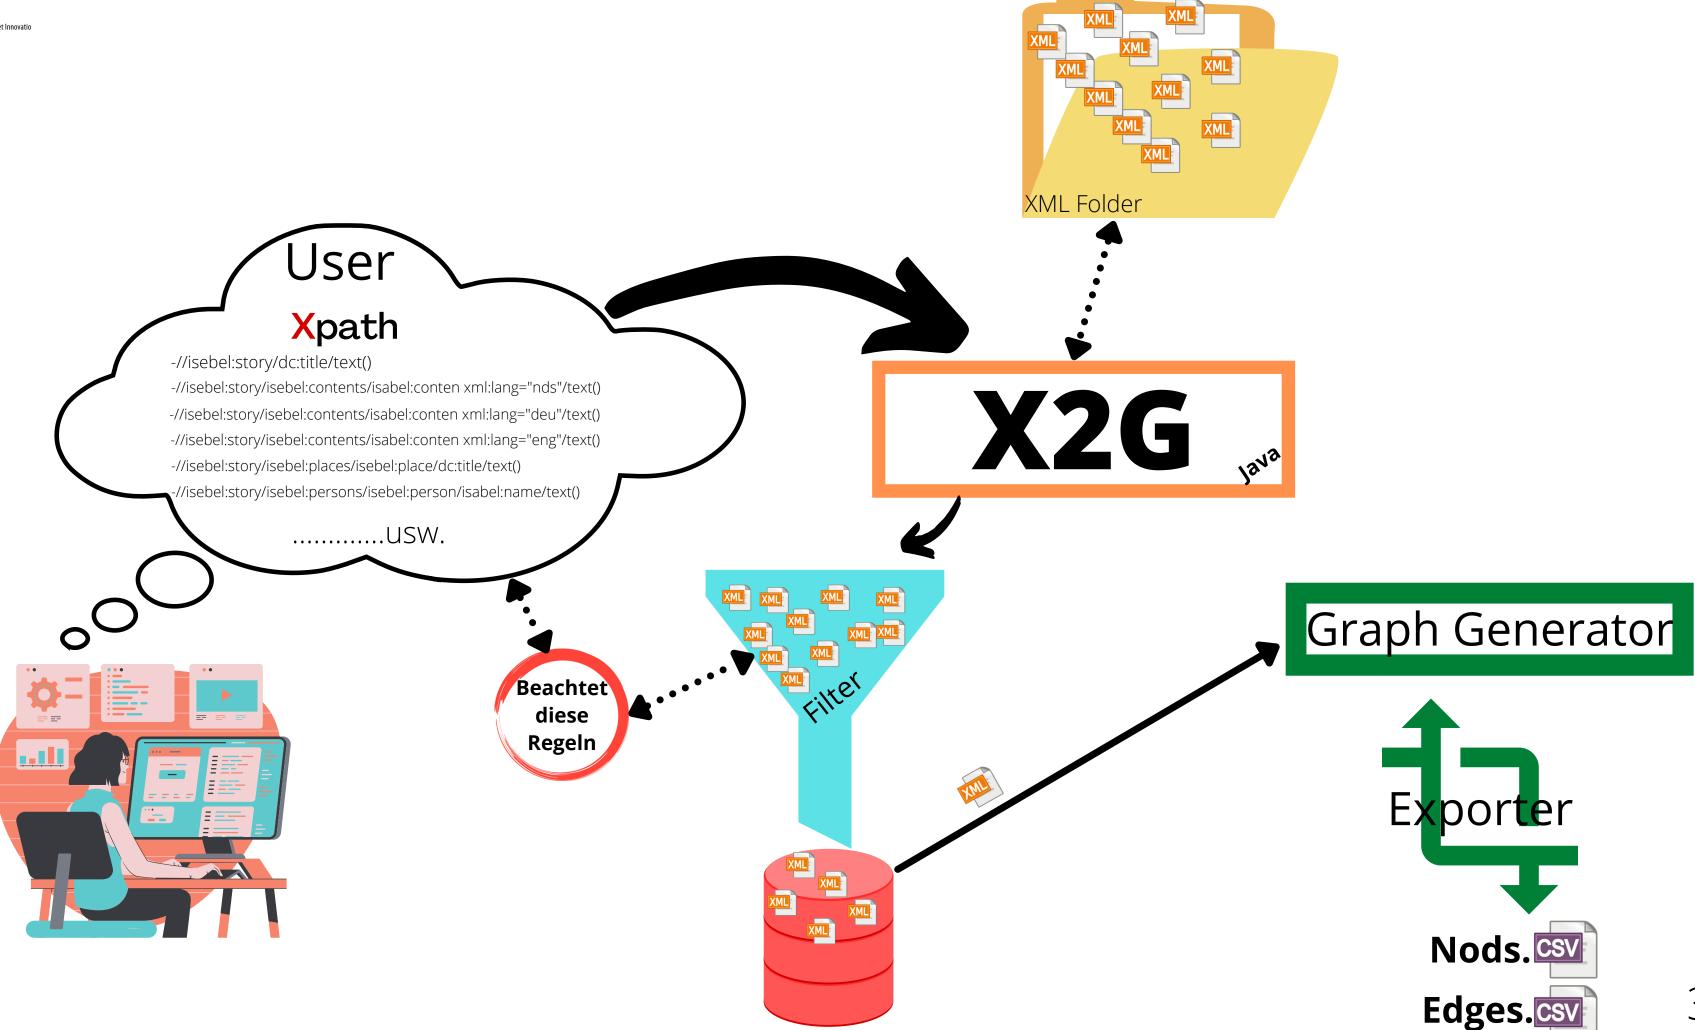
**Gephi** (Beispiel)



### X2G beantwortet die folgenden Fragen

- Dokumentstruktur wird nicht 1-zu-1 in Graphstruktur überführt
- Welche XML-Dokumenten werden bearbeitet
- Die Property-Graphstruktur: Knoten und Kanten mit Eigenschaften
- Bestimmte Regeln f
  ür die Erstellung von Knoten und Kanten
- Das Format der Ausgabe der generierten Graphen



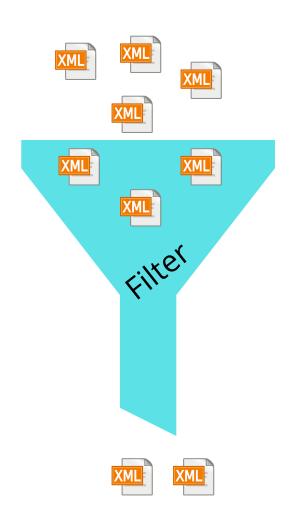




### Wie funktioniert der Filter?

und warum brauchen wir einen Filter?

Filter verwendet XPath-Ausdrücke, um jede XML-Datei zu überprüfen, ob sie die Kriterien (Regeln) des Benutzers erfüllt.





```
▼<isebel:story xmlns:isebel="http://www.isebel.eu/ns/isebel" xmlns:dc="http://purl.org/dc/elements/1.1/" xmlns:html="http://www.w3.org/1999/xhtml" xml:id="xmd-s001-000-000-030" xml:lang="deu">
   <dc:identifier>de.wossidia.xmd-s001-000-000-030</dc:identifier>
  <isebel:purl>https://apps.wossidia.de/webapp/run/node/XMD-S001-000-000-030</isebel:purl>
  <dc:title>[30] Der gefundene Schatz macht standesgemäß</dc:title>
  <dc:title xml:lang="nds"/>
  <dc:title xml:lang="deu"/>
  <dc:title xml:lang="eng"/>
 ▼<isebel:contents>
    <isebel:content xml:lang="nds">Kleekamp willen poor Daglöhner Holt stietzen. 「Dat¹ is 「noch tiedigen¹ Morgen. 「Se kamen an 'ne¹ Kuul mit Steen 「vörbi¹. Een mööt ut de Hosen. 「He¹ will 「solang'¹
    Dorvon het de Herr en Stuuv bugen laten in't Herrenhuus. Erzähler: H. Müller, Hohen Viechein, Kreis Wismar; Aufzeichner: Wossidlo, 21. 5. 1932.</isebel:content>
    <isebel:content xml:lang="deu">In Kleekamp wollen ein paar Tagelöhner Holz stehlen. Es ist noch sehr zeitig am Morgen. Sie kommen an einer Steingrube vorbei. Einer von ihnen muß mal in die
    altmodisch gewesen. Er hat es aber genommen und umgewechselt. Davon hat ihm der Herr im Herrenhaus eine Stube bauen lassen.</isebel:content>
    <isebel:content xml:lang="eng">A few daytaller wanted to steal some wood. It was very early in the morning. They passed a stone pit. One of them had to go in the bushes. Whilst he wanted to
    From that profit, the squire had a room in the manor built for him.</isebel:content>
   </isebel:contents>
 ▼<isebel:places>
   ▼<isebel:place id="100001174">
      <dc:title>Hohen Viecheln</dc:title>
     ▼<isebel:point>
        <datacite:pointLatitude xmlns:datacite="http://datacite.org/schema/kernel-4">53.78404</datacite:pointLatitude>
        <datacite:pointLongitude xmlns:datacite="http://datacite.org/schema/kernel-4">11.51169</datacite:pointLongitude>
      </isebel:point>
      <isebel:role>narration</isebel:role>
     </isebel:place>
  </isebel:places>
 ▼<isebel:events>
   ▼<isebel:event id="990013673">
      <isebel:date>1932-05-21</isebel:date>
      <isebel:role>narration</isebel:role>
    </isebel:event>
  </isebel:events>
 ▼<isebel:keywords>
    <isebel:keyword id="XMD-M030-000-000-640" type="controlled vocabulary" provenance="WossiDiA-Index">Schätze</isebel:keyword>
    <isebel:keyword id="XMD-M030-000-004-718" type="controlled vocabulary" provenance="WossiDiA-Index">finden</isebel:keyword>
    <isebel:keyword id="XMD-M030-000-008-000" type="controlled vocabulary" provenance="WossiDiA-Index">nehmen (untersch. Bed.)</isebel:keyword>
    <isebel:keyword xml:lang="deu" id="ZAW-B802" type="controlled vocabulary" provenance="RW-Index">Schätze</isebel:keyword>
    <isebel:keyword xml:lang="eng" id="ZAW-B802" type="controlled vocabulary" provenance="RW-Index">treasure</isebel:keyword>
    <isebel:keyword xml:lang="deu" id="ZAW-B802-017" type="controlled vocabulary" provenance="RW-Index">Den gefundenen Schatz nimmt ein anderer</isebel:keyword>
    <isebel:keyword xml:lang="eng" id="ZAW-B802-017" type="controlled vocabulary" provenance="RW-Index">The found treasure takes another</isebel:keyword>
  </isebel:keywords>
  ▼<isebel:imageResources>
   ▼<isebel:imageResource id="ZAW-B802-017-009-001">
      <isebel:purl>https://apps.wossidia.de/digipool/3babc7eb/master</isebel:purl>
    </isebel:imageResource>
   ▼<isebel:imageResource id="ZAW-B802-017-009-002">
      <isebel:purl>https://apps.wossidia.de/digipool/3babc7ec/master</isebel:purl>
    </isebel:imageResource>
   </isebel:imageResources>
 </isebel:story>
```



```
(isebel:story xmlns:isebel="http://www.isebel.eu/ns/isebel" xmlns:dc="http://purl.org/dc/elements/1.1/" xmlns:html="http://www.w3.org/1999/xhtml" xml:id="xmd-s001-000-000-000" xml:lang="deu">
 <dc:identifier>de.wossidia.xmd-s001-000-000-005</dc:identifier>
 <isebel:purl>https://apps.wossidia.de/webapp/run/node/XMD-S001-000-000-005</isebel:purl>
 <dc:title>[5] Edelmann wird totgeschlagen, nachdem er Mätresse misshandelt hat</dc:title>
 <dc:title xml:lang="nds"/>
 <dc:title xml:lang="deu"/>
v<isebel:contents>
   <isebel:content xml:lang="nds">De Eddelmann in Stellshagen het en Diern so mißhannelt, de het toletzt 'n Stoeker nahmen un is up em ingahn. Un de Lüüd hebben em von'n Pierd krägen un doots!
   de hebben sik flüchtt, de annern sünd faatt. - Gerichts schlag heet dat hüüt noch. As fief all richtt sünd, un de sösst ran sall, kümmt Ordre von Swerin, se süllen bloß enen richten. Dat h
   <isebel:content xml:lang="deu">Der Edelmann in Stellshagen hat ein Mädchen so mißhandelt, die hat zuletzt den Stock genommen und ist auf ihn eingedrungen. Und seine Leute haben ihn vom Pfer
   Wassertümpel, da sind viele hindurchgeschwommen, die haben sich geflüchtet. Die anderen sind gefaßt worden. - Gerichtsschlag heißt es ja noch heute dort. - Als fünf schon hingerichtet sind
   </isebel:content>
 </isebel:contents>
v<isebel:places>
 ▼<isebel:place id="100001174">
     <dc:title>Hohen Viecheln</dc:title>
   ▼<isebel:point>
       <datacite:pointLatitude xmlns:datacite="http://datacite.org/schema/kernel-4">53.78404</datacite:pointLatitude>
       <datacite:pointLongitude xmlns:datacite="http://datacite.org/schema/kernel-4">11.51169</datacite:pointLongitude>
     <isebel:role>narration</isebel:role>
   </isebel:place>
 ▼<isebel:place id="100002701">
     <dc:title>Stellshagen</dc:title>
   ▼<isebel:point>
       <datacite:pointLatitude xmlns:datacite="http://datacite.org/schema/kernel-4">53.94487</datacite:pointLatitude>
       <datacite:pointLongitude xmlns:datacite="http://datacite.org/schema/kernel-4">11.13973</datacite:pointLongitude>
     <isebel:role>action</isebel:role>
   </isebel:place>
 </isebel:places>

/<isebel:persons>

 ▼<isebel:person id="110002742">
     <isebel:name>Hinrichs</isebel:name>
     <isebel:gender>male</isebel:gender>
     <isebel:role>narrator</isebel:role>
     <isebel:profession>Pantoffelmacher</isebel:profession>
   </isebel:person>
 </isebel:persons>
▼<isebel:keywords>
   <isebel:keyword id="XMD-M030-000-001-053" type="controlled vocabulary" provenance="WossiDiA-Index">Edelleute</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-005-606" type="controlled vocabulary" provenance="WossiDiA-Index">Haberlandt</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-030-625" type="controlled vocabulary" provenance="WossiDiA-Index">Frevelsage</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-000-0023" type="controlled vocabulary" provenance="WossiDiA-Index">Wasser</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-000-595" type="controlled vocabulary" provenance="WossiDiA-Index">Wasserlauf</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-000-782" type="controlled vocabulary" provenance="WossiDiA-Index">Edelmann</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-001-198" type="controlled vocabulary" provenance="WossiDiA-Index">Geld</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-001-526" type="controlled vocabulary" provenance="WossiDiA-Index">totschlagen</isebel:keyword>
   <isebel:keyword id="XMD-M030-000-001-977" type="controlled vocabulary" provenance="WossiDiA-Index">Leute</isebel:keyword>
  <isebel:keyword xml:lang="nds" id="XMD-M030-000-002-413" type="controlled vocabulary" provenance="WossiDiA-Index">Dirn</isebel:keyword>
<isebel:keyword xml:lang="nds" id="XMD-M030-000-018-226" type="controlled vocabulary" provenance="WossiDiA-Index">Scheid'</isebel:keyword>
<isebel:keyword id="XMD-M030-000-025-600" type="controlled vocabulary" provenance="WossiDiA-Index">Mätress</isebel:keyword>

 <isebel:keyword id="XMD-M030-000-038-232" type="controlled vocabulary" provenance="WossiDiA-Index">misshandeln</isebel:keyword>
<isebel:keyword id="XMD-M030-000-040-933" type="controlled vocabulary" provenance="WossiDiA-Index">besprechen</isebel:keyword>
<isebel:keyword xml:lang="deu" id="ZAW-B609" type="controlled vocabulary" provenance="RW-Index">Frevel</isebel:keyword>
<isebel:keyword xml:lang="eng" id="ZAW-B609" type="controlled vocabulary" provenance="RW-Index">sacrilege</isebel:keyword>
<isebel:keyword xml:lang="deu" id="ZAW-B609-001" type="controlled vocabulary" provenance="RW-Index">hade: "Abberlandt</isebel:keyword>
<isebel:keyword xml:lang="deu" id="ZAW-B609-001" type="controlled vocabulary" provenance="RW-Index">hade: "Abberlandt</isebel:keyword>
<isebel:keyword xml:lang="deu" id="ZAW-B609-001" type="controlled vocabulary" provenance="RW-Index">hade: "Abberlandt</isebel:keyword>

  <isebel:keyword xml:lang="eng" id="ZAW-B609-001" type="controlled vocabulary" provenance="RW-Index">Haberlandt</isebel:keyword>
 </isebel:keywords>
▼<isebel:imageResources>
 ▼<isebel:imageResource id="ZAW-B609-001-012-002">
     <isebel:purl>https://apps.wossidia.de/digipool/3bab5921/master</isebel:purl>
   </isebel:imageResource>
 ▼<isebel:imageResource id="ZAW-B609-001-012-001">
     <isebel:purl>https://apps.wossidia.de/digipool/3bab5920/master</isebel:purl>
   </isebel:imageResource>
 </isebel:imageResources>
/isebel:story>
```



### 3.Beispiel mit deutschen und englischen Text der Sage



### 5.Beispiel

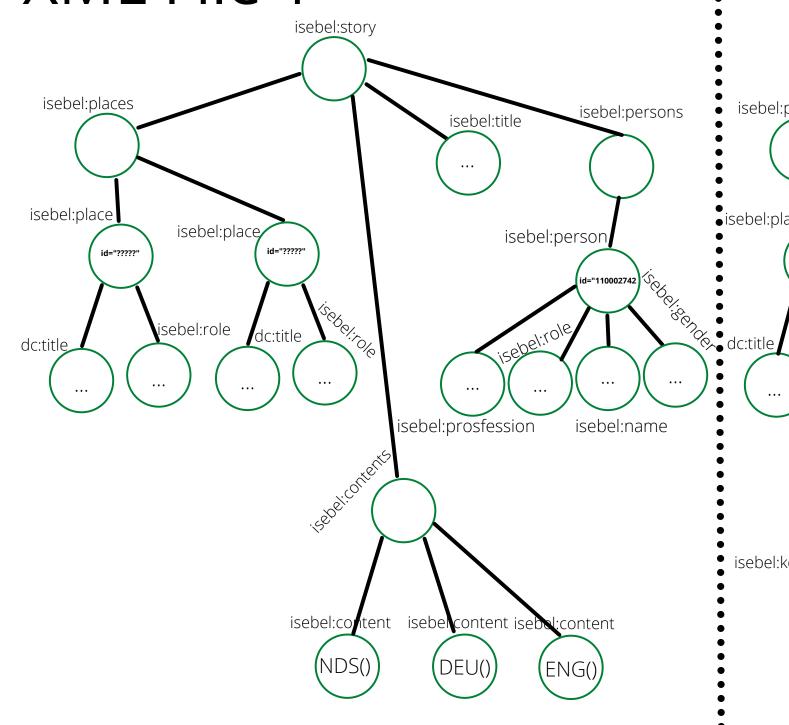
Sage in Hochdeutsch mit direkter Rede in Niederdeutsch



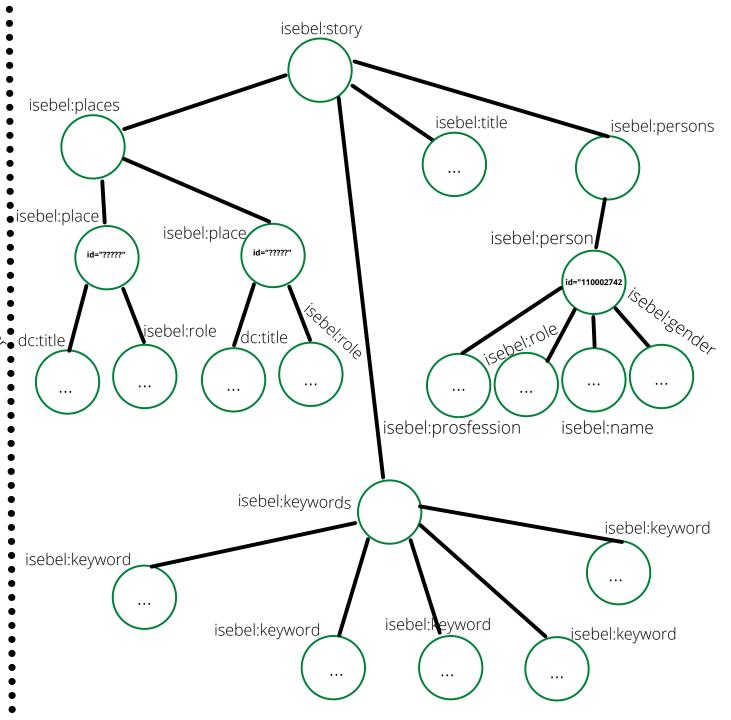
#### XML als Baumstruktur

Persons names (Heinrich, Dettmann)
Persons genders --> (z.B. male)
Places names --> (Stellshagen, Rostck, ... )

### XML File 1



### XML File 2

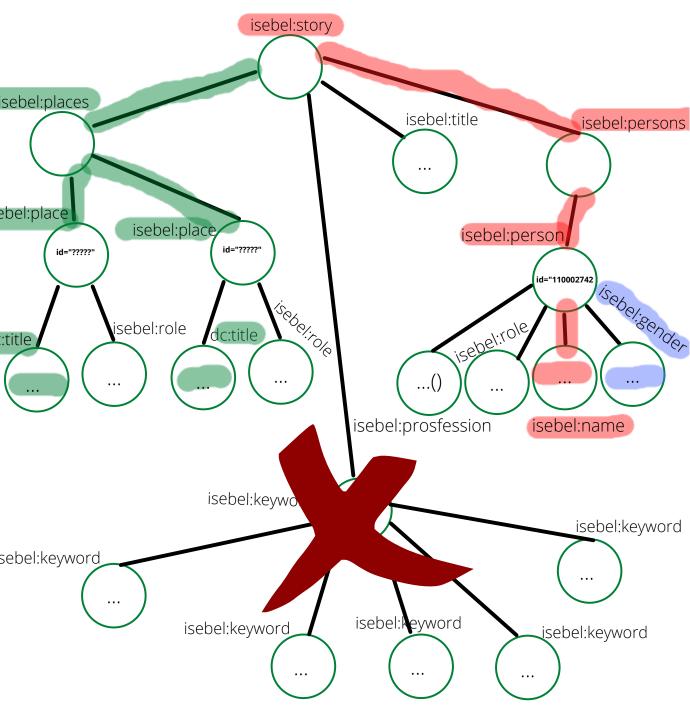




#### XML als Baumstruktur

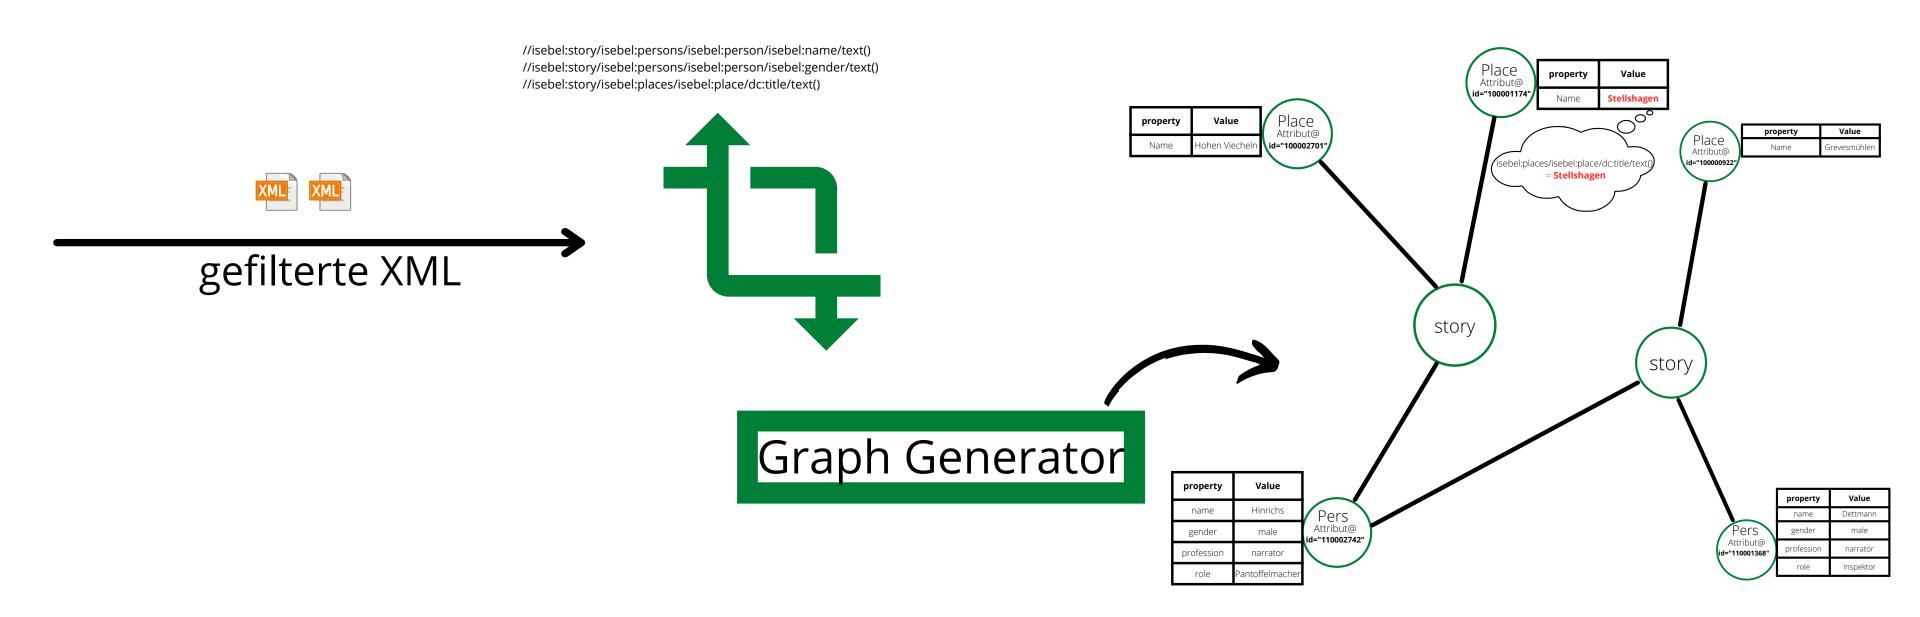
//isebel:story/isebel:persons/isebel:person/isebel:name/text() Persons names //isebel:story/isebel:persons/isebel:person/isebel:gender/text() Persons genders /<mark>/isebel:story/</mark>isebel:places/isebel:place/dc:title/text() Places names

#### XML File 2 XML File 1 isebel:places isebel:persons isebel:places isebel:title isebel:place isebel:place isebel:place isebel:place isebel:person isebel:role isebel:role dc:title dc:title isebel:prosfession isebel:name isebel:keyword isebel:content isebel:content isebel:content (NDS() DEU() ENG()





### Graph Generator





Wir zeigen schrittweise das Generieren des Graphens aus den extrahierten XML-Fragmenten am Beispiel!







create node "story"



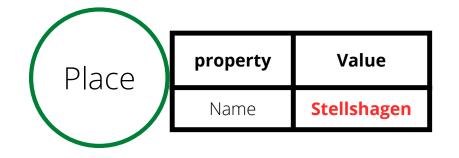
### create node "place"





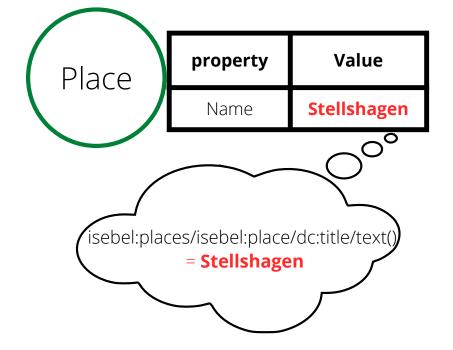


property name = "Stellshagen"



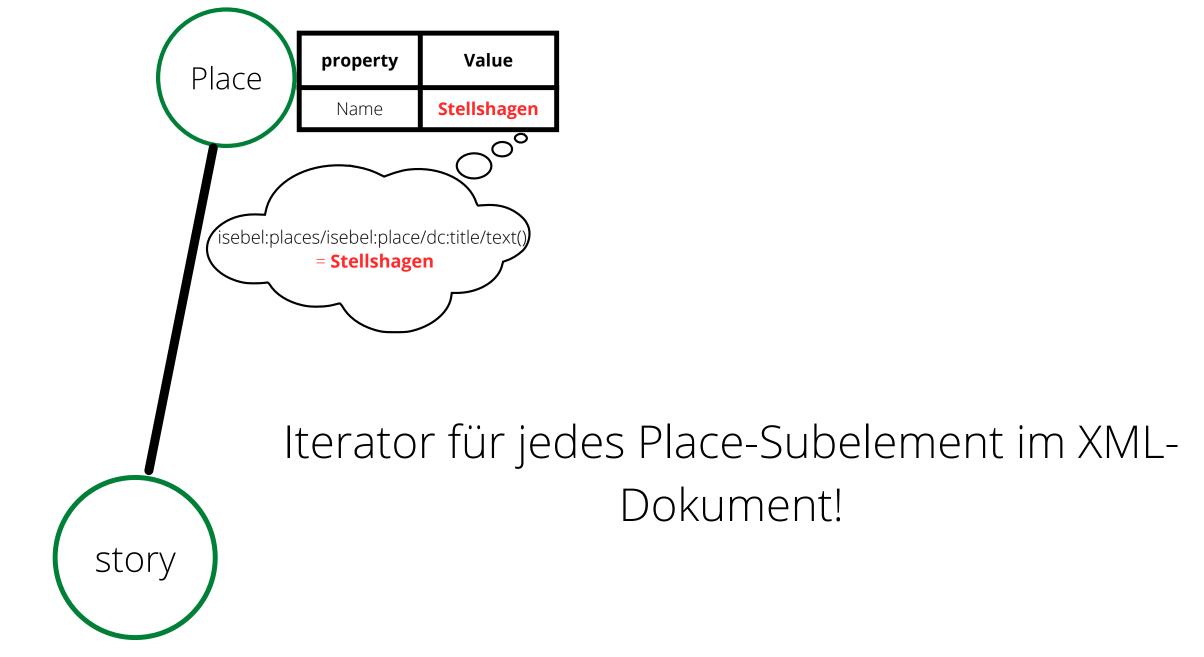






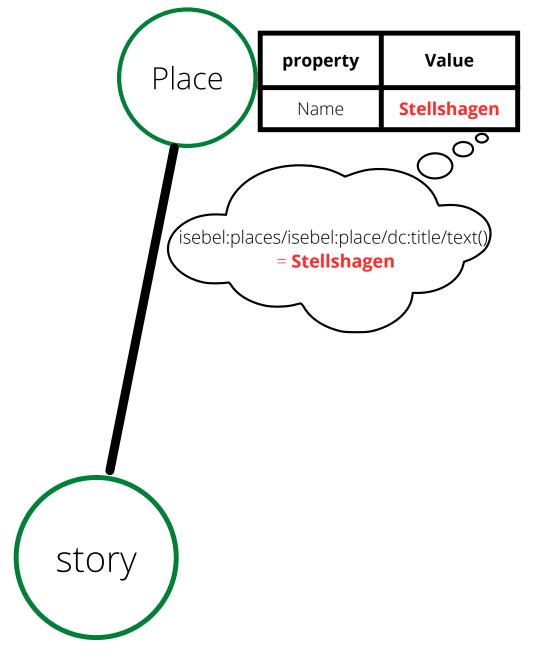




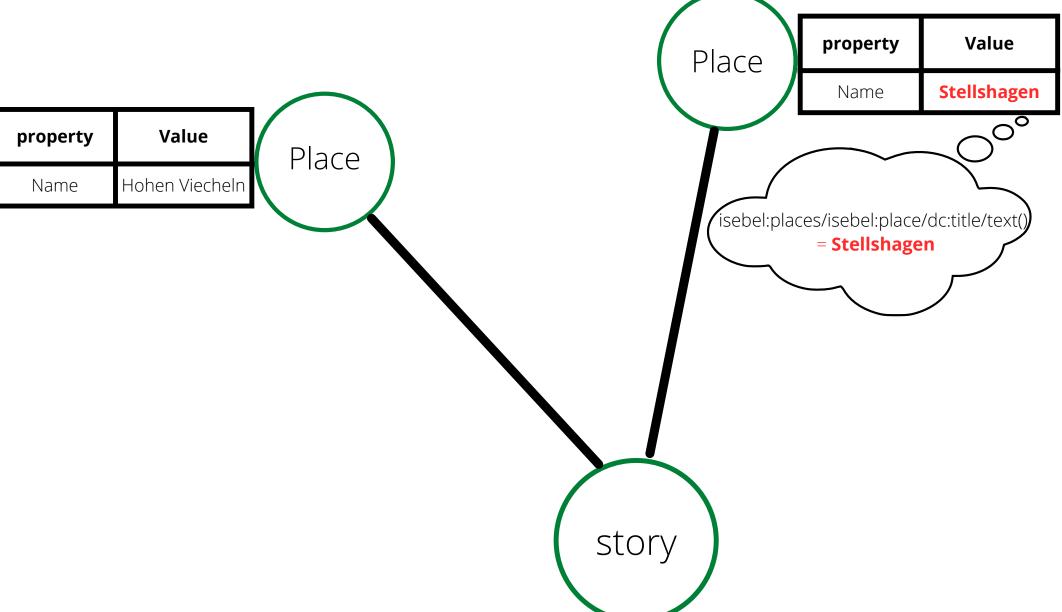




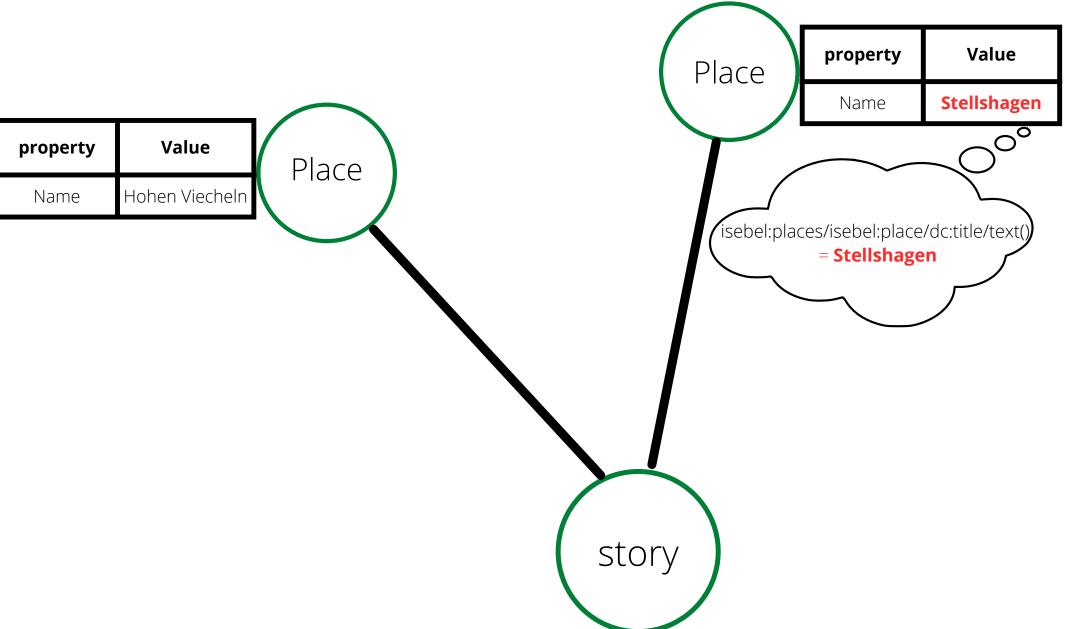
property	Value	Place
Name	Hohen Viecheln	Trace





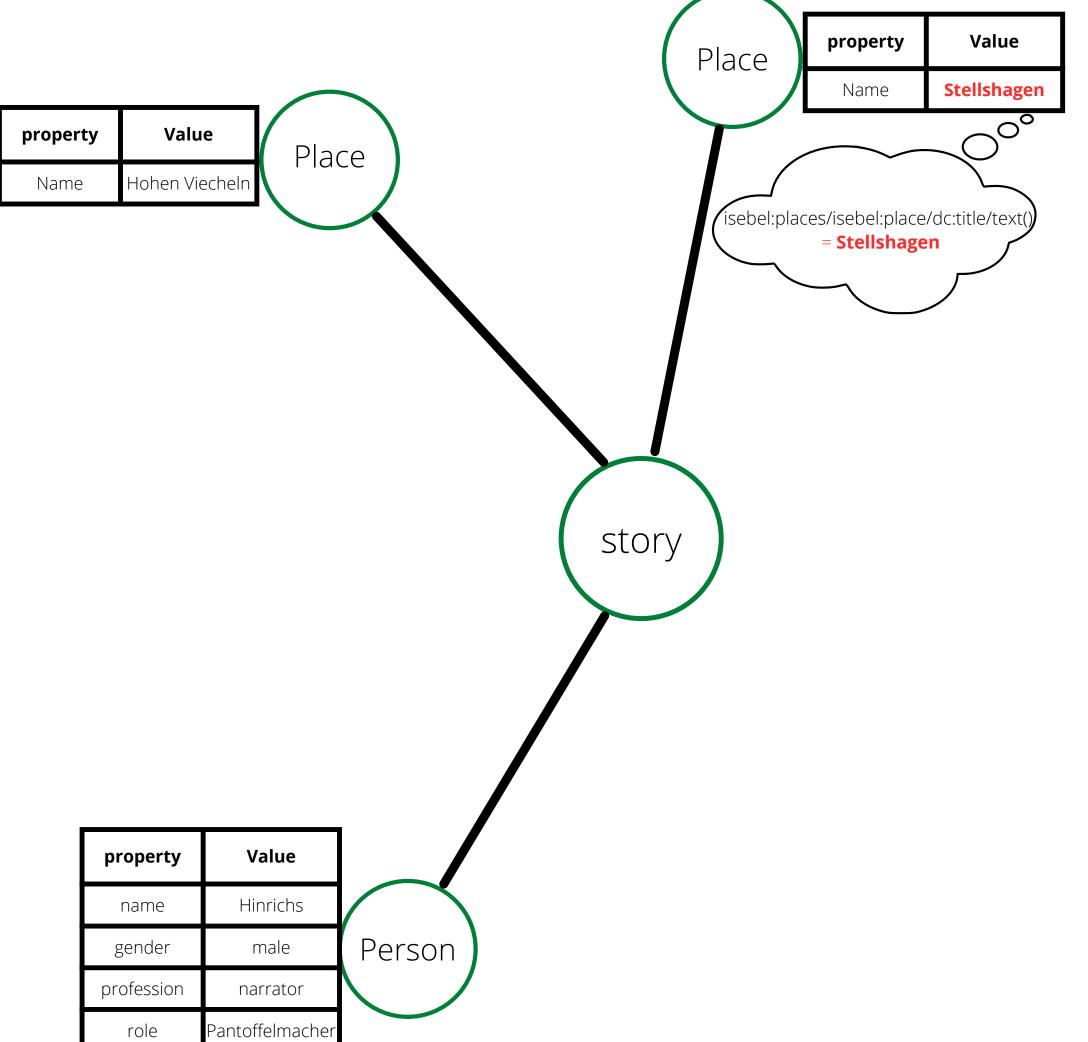






property	Value	
name	Hinrichs	
gender	male	Person
profession	narrator	
role	Pantoffelmacher	

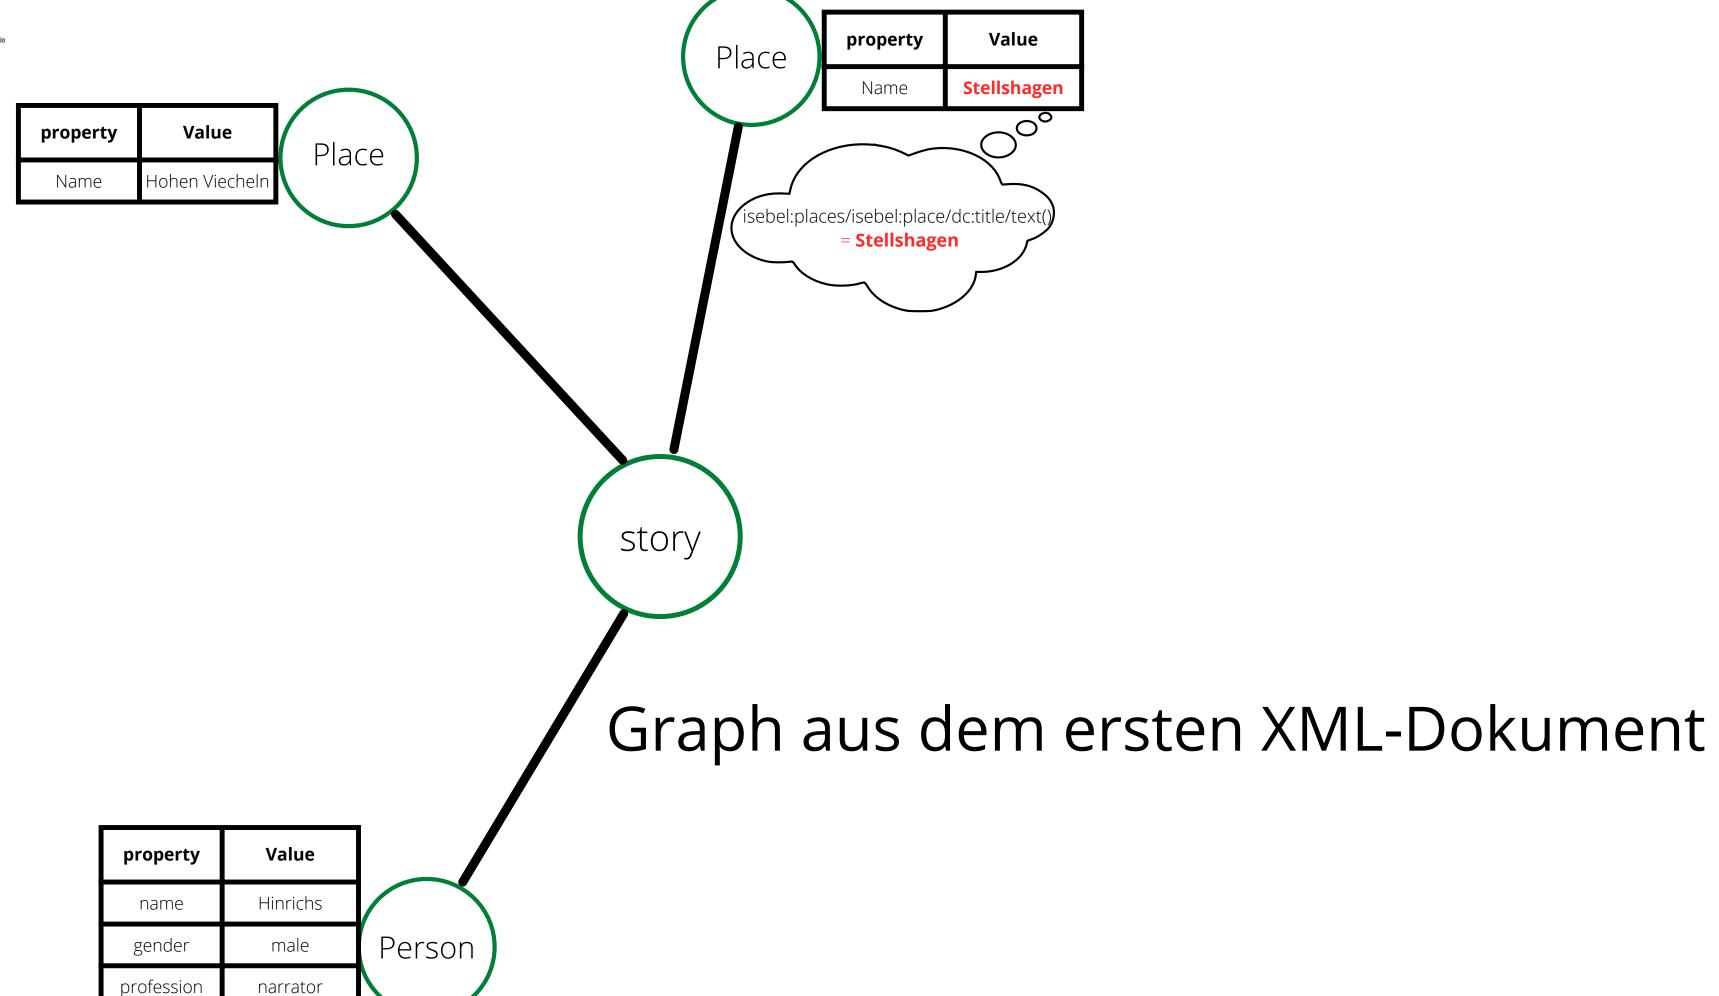






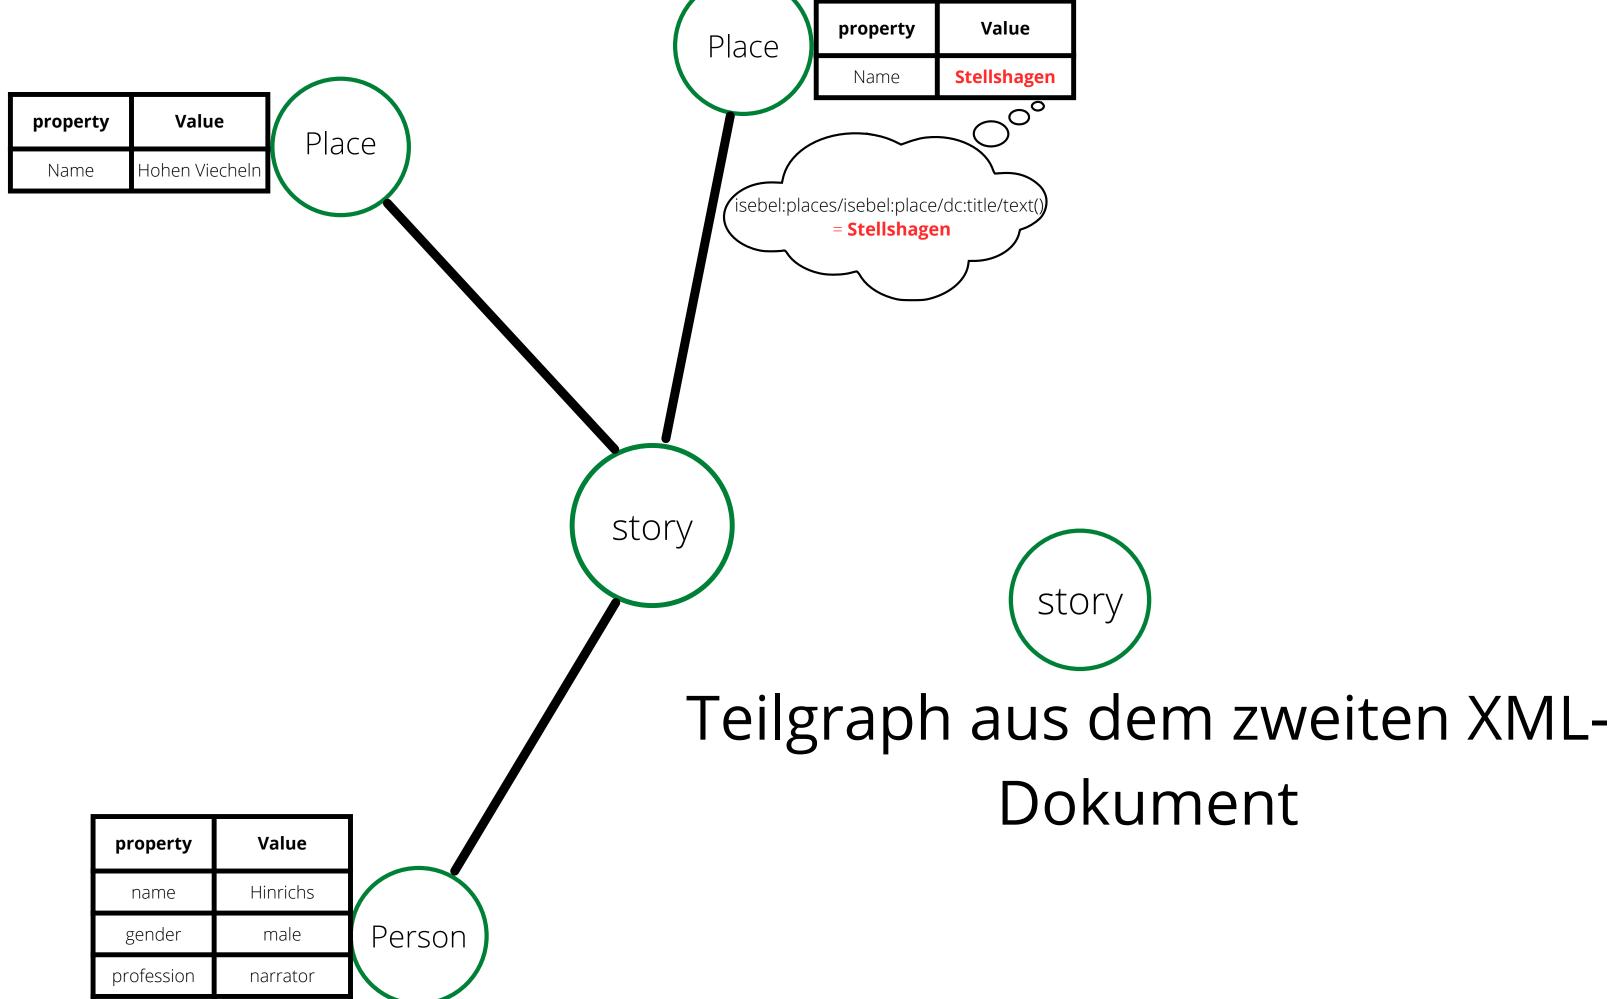
narrator

Pantoffelmacher

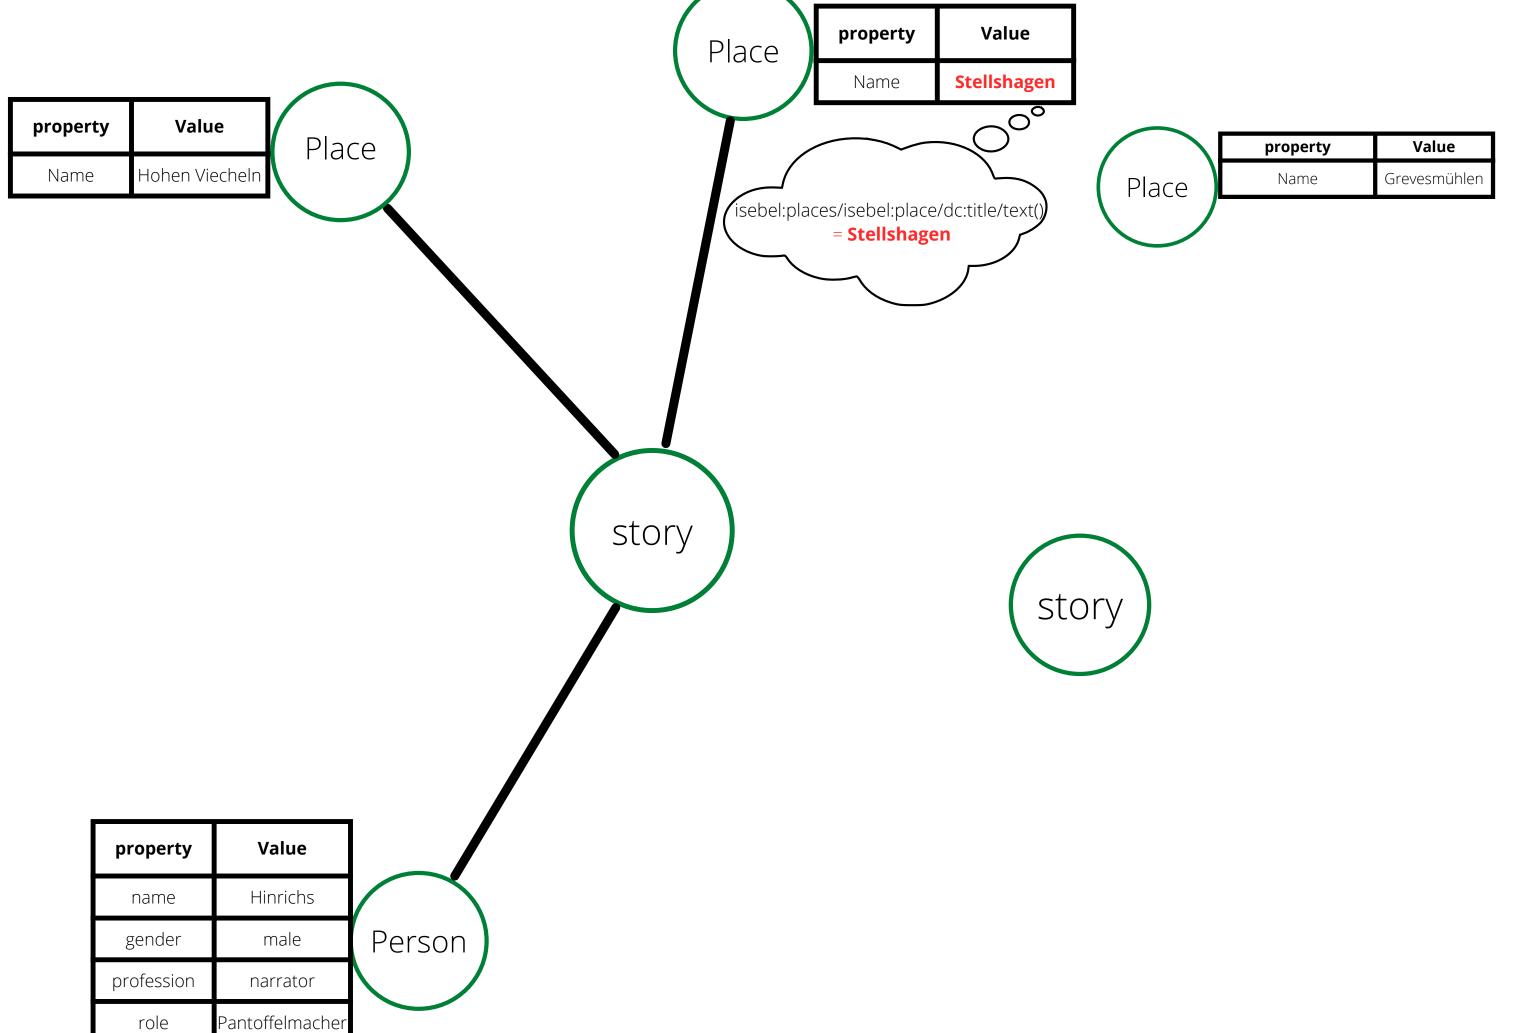




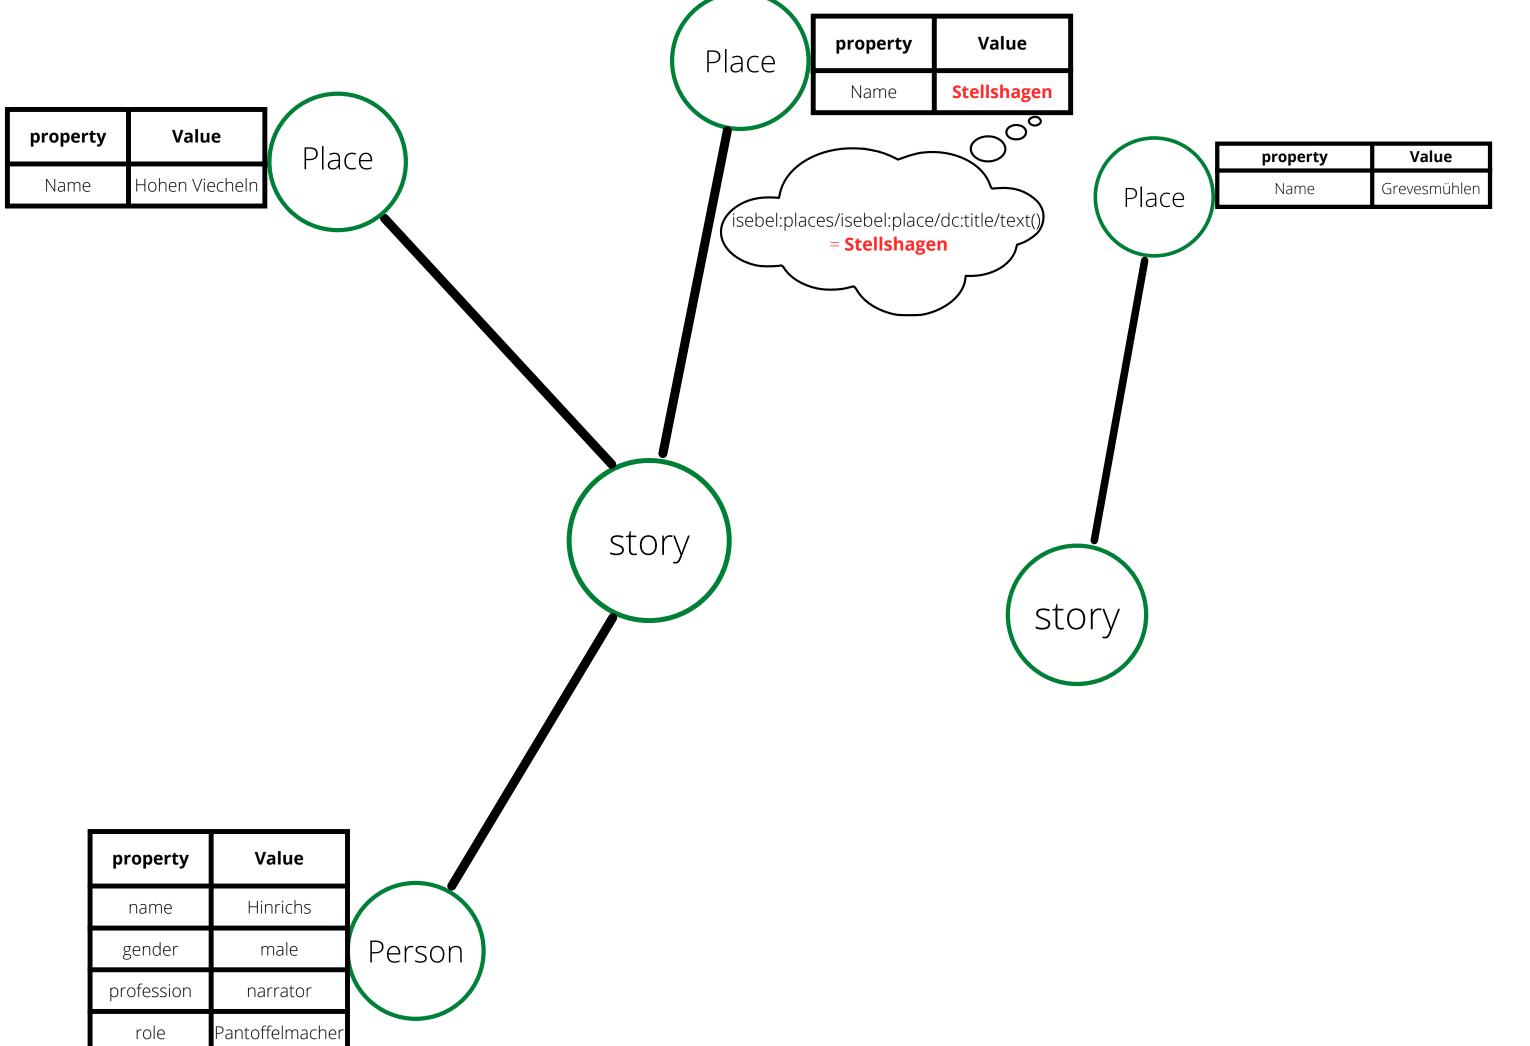
. Pantoffelmacher



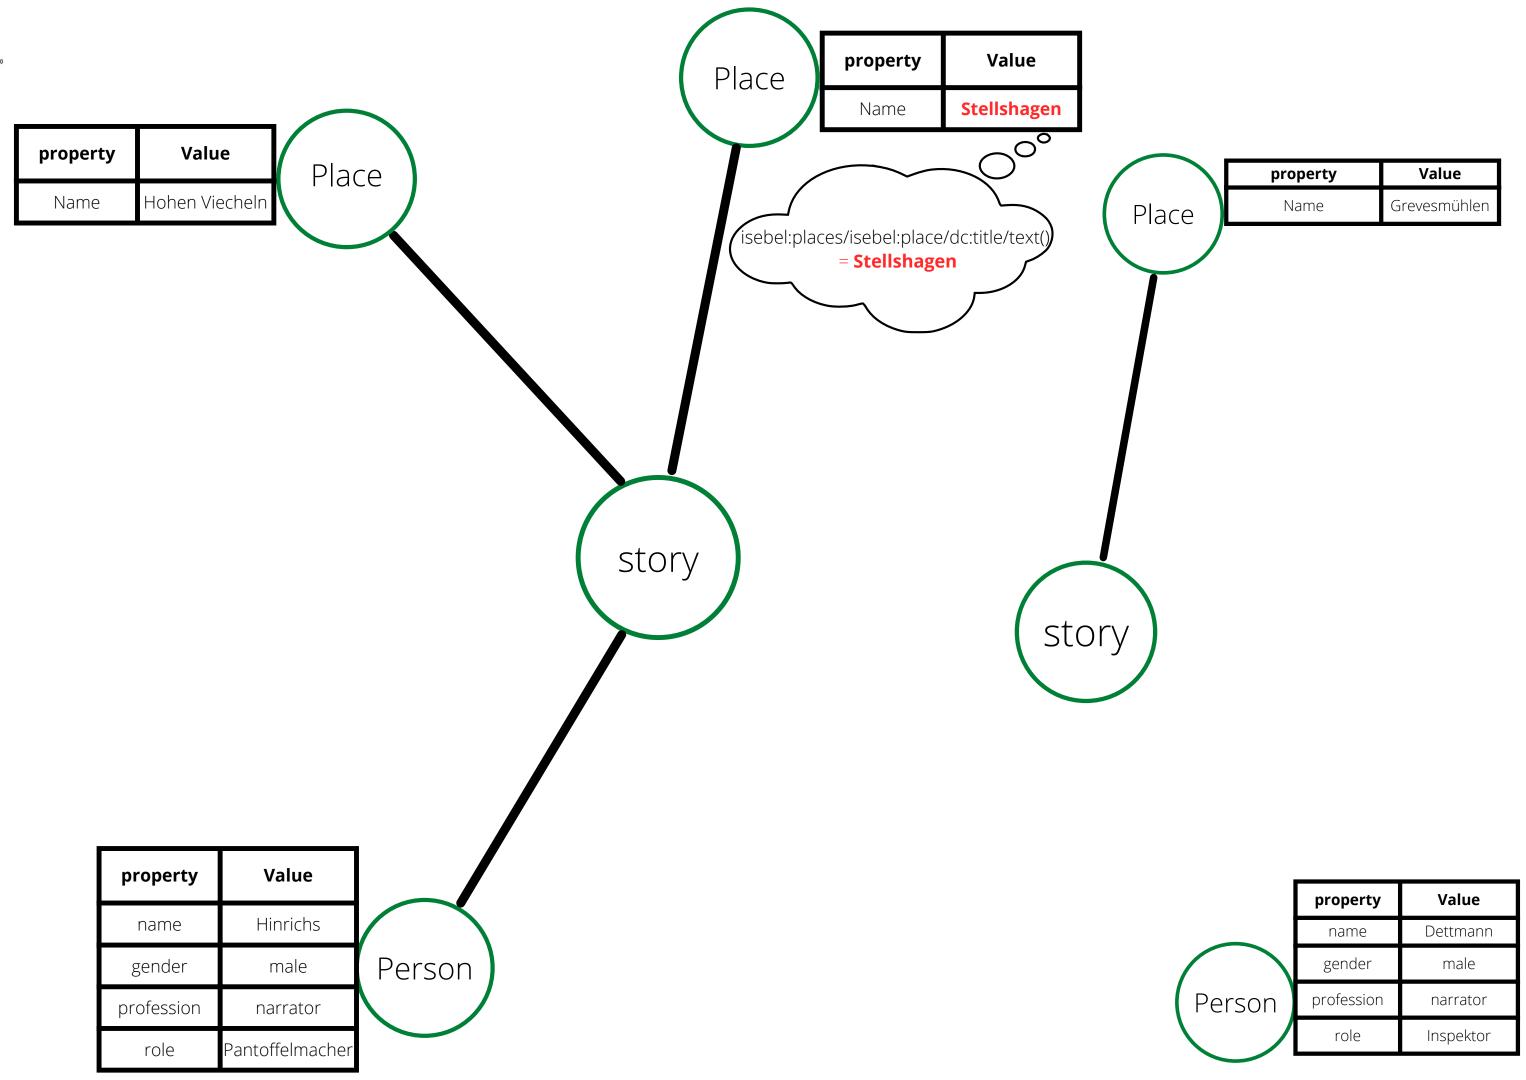


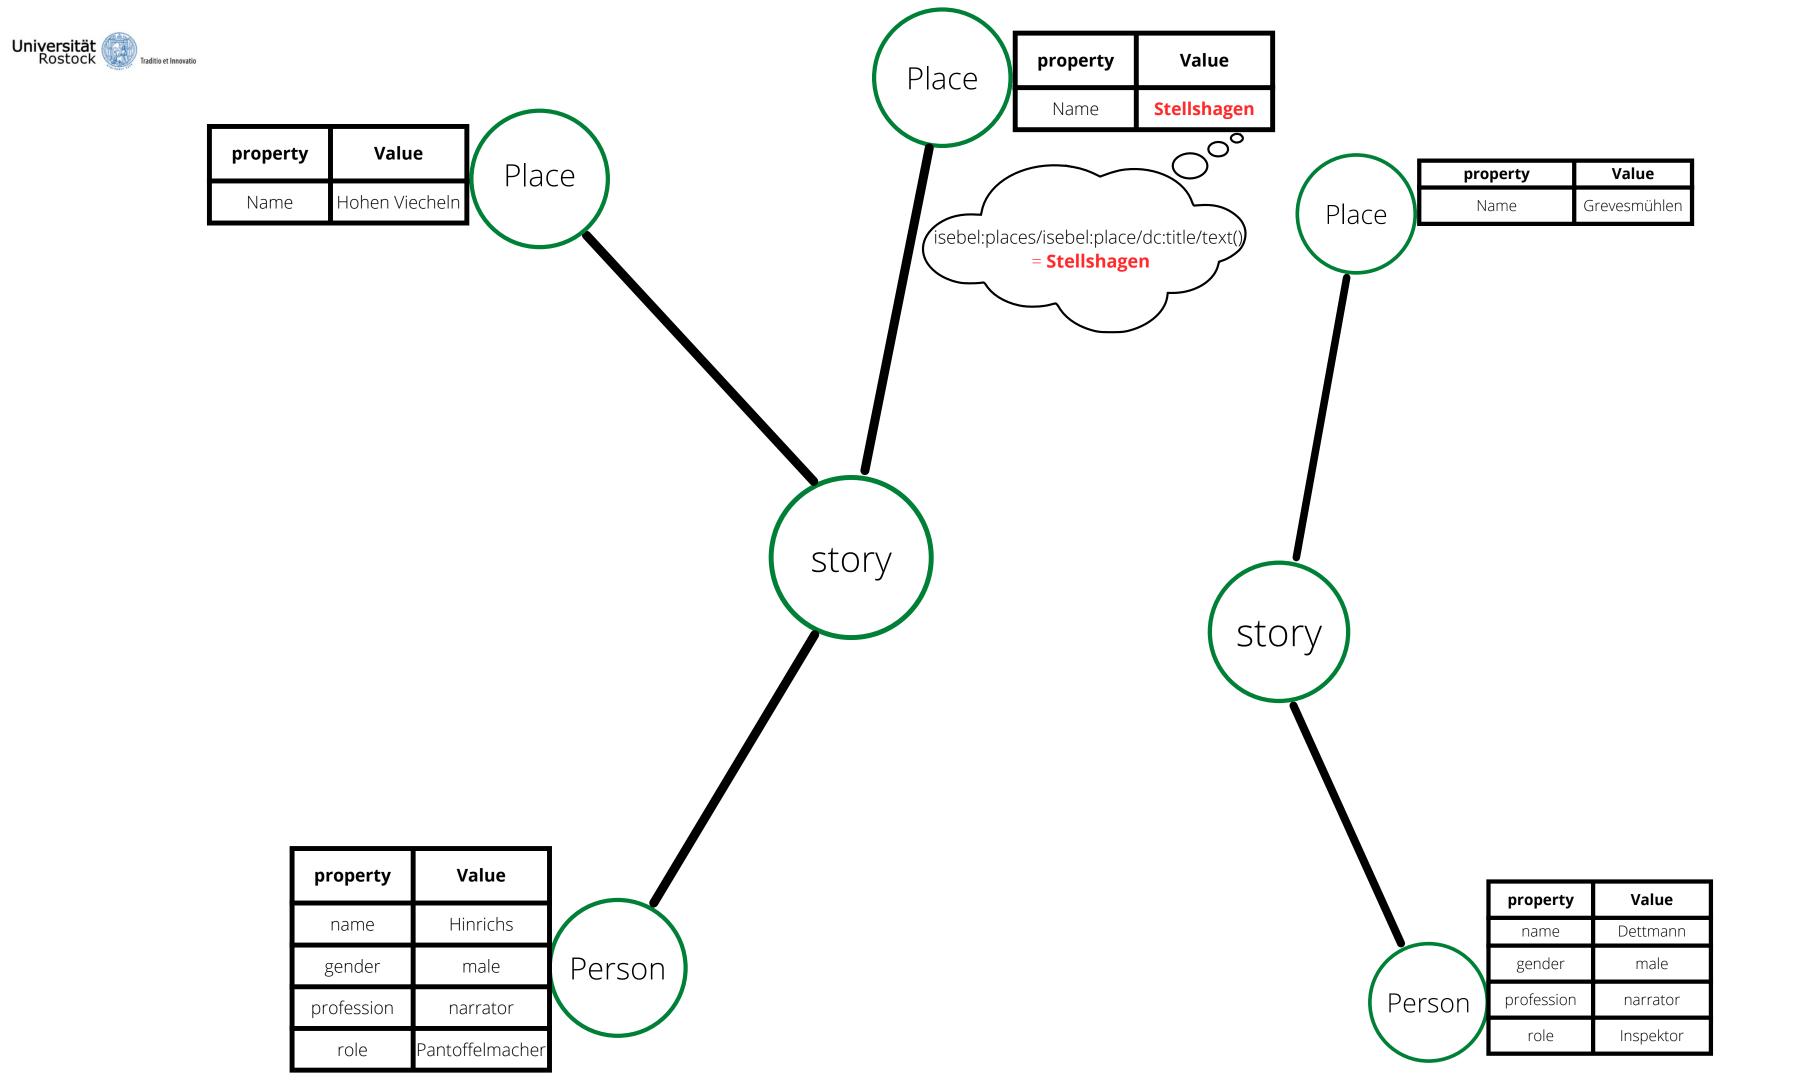


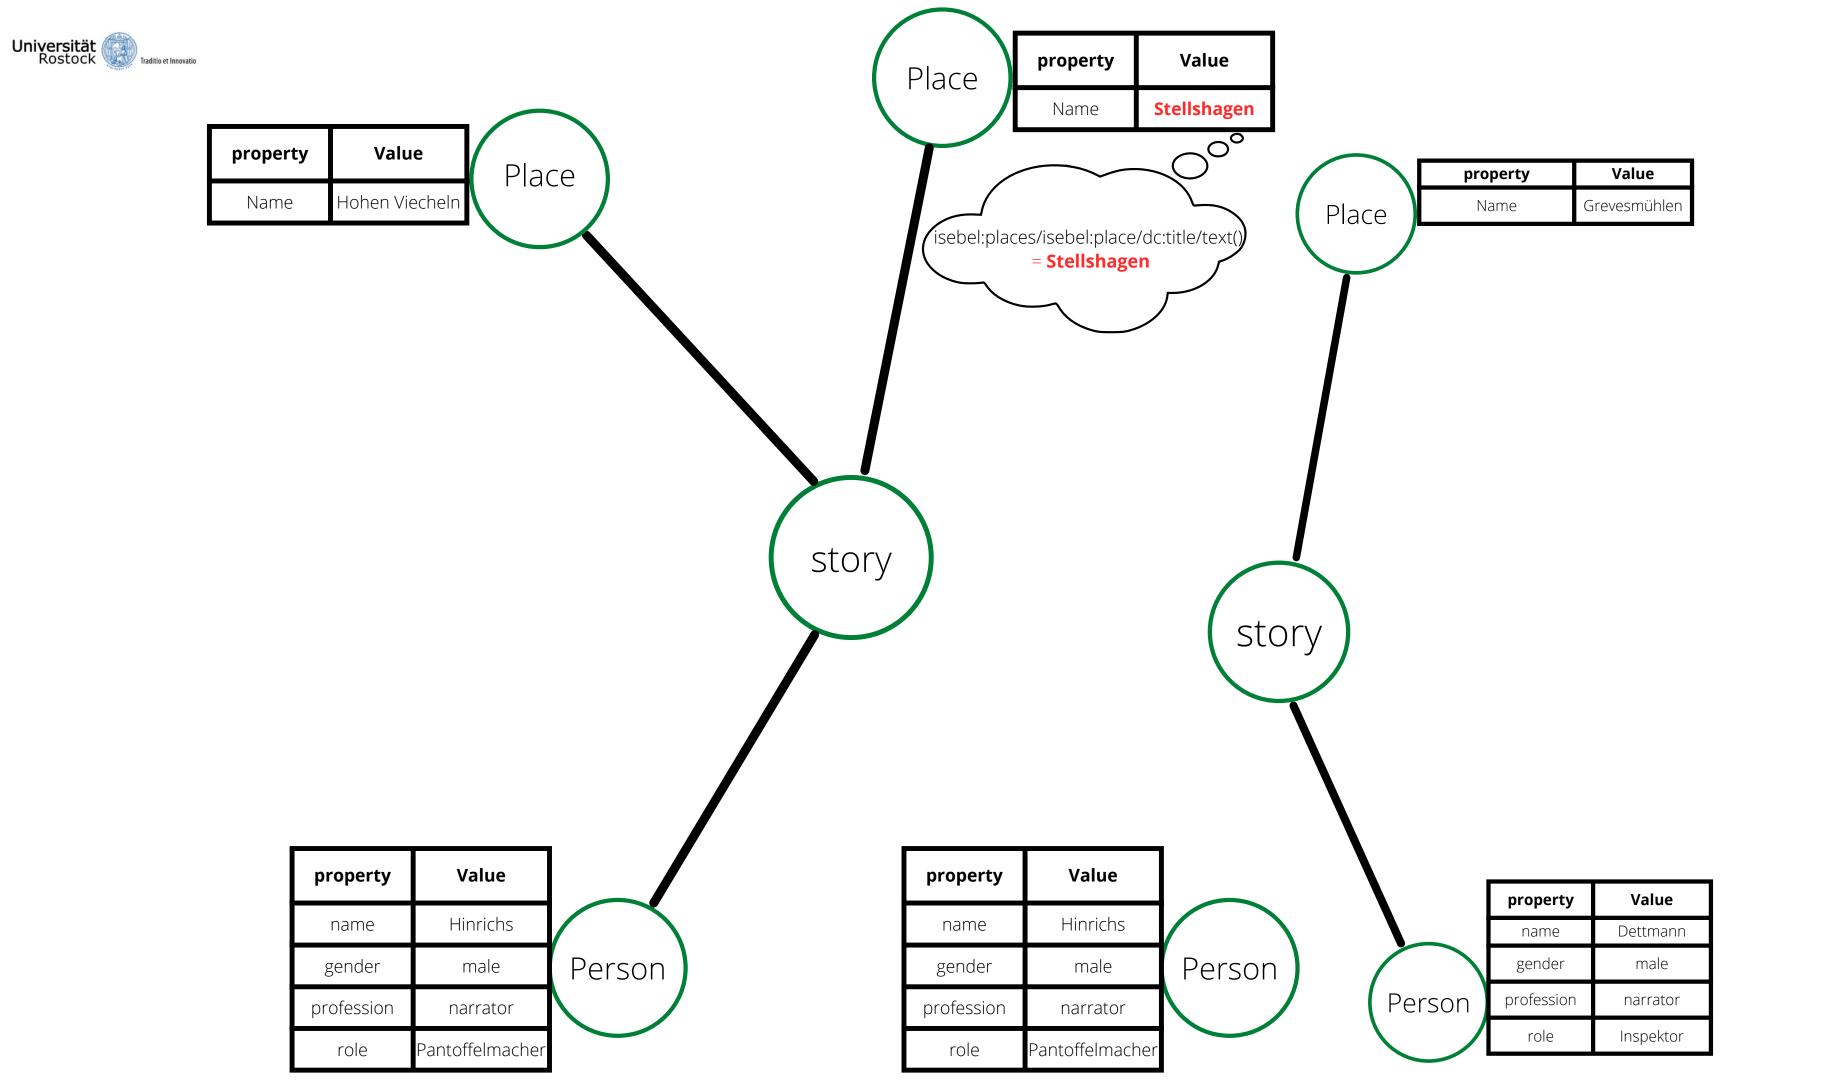


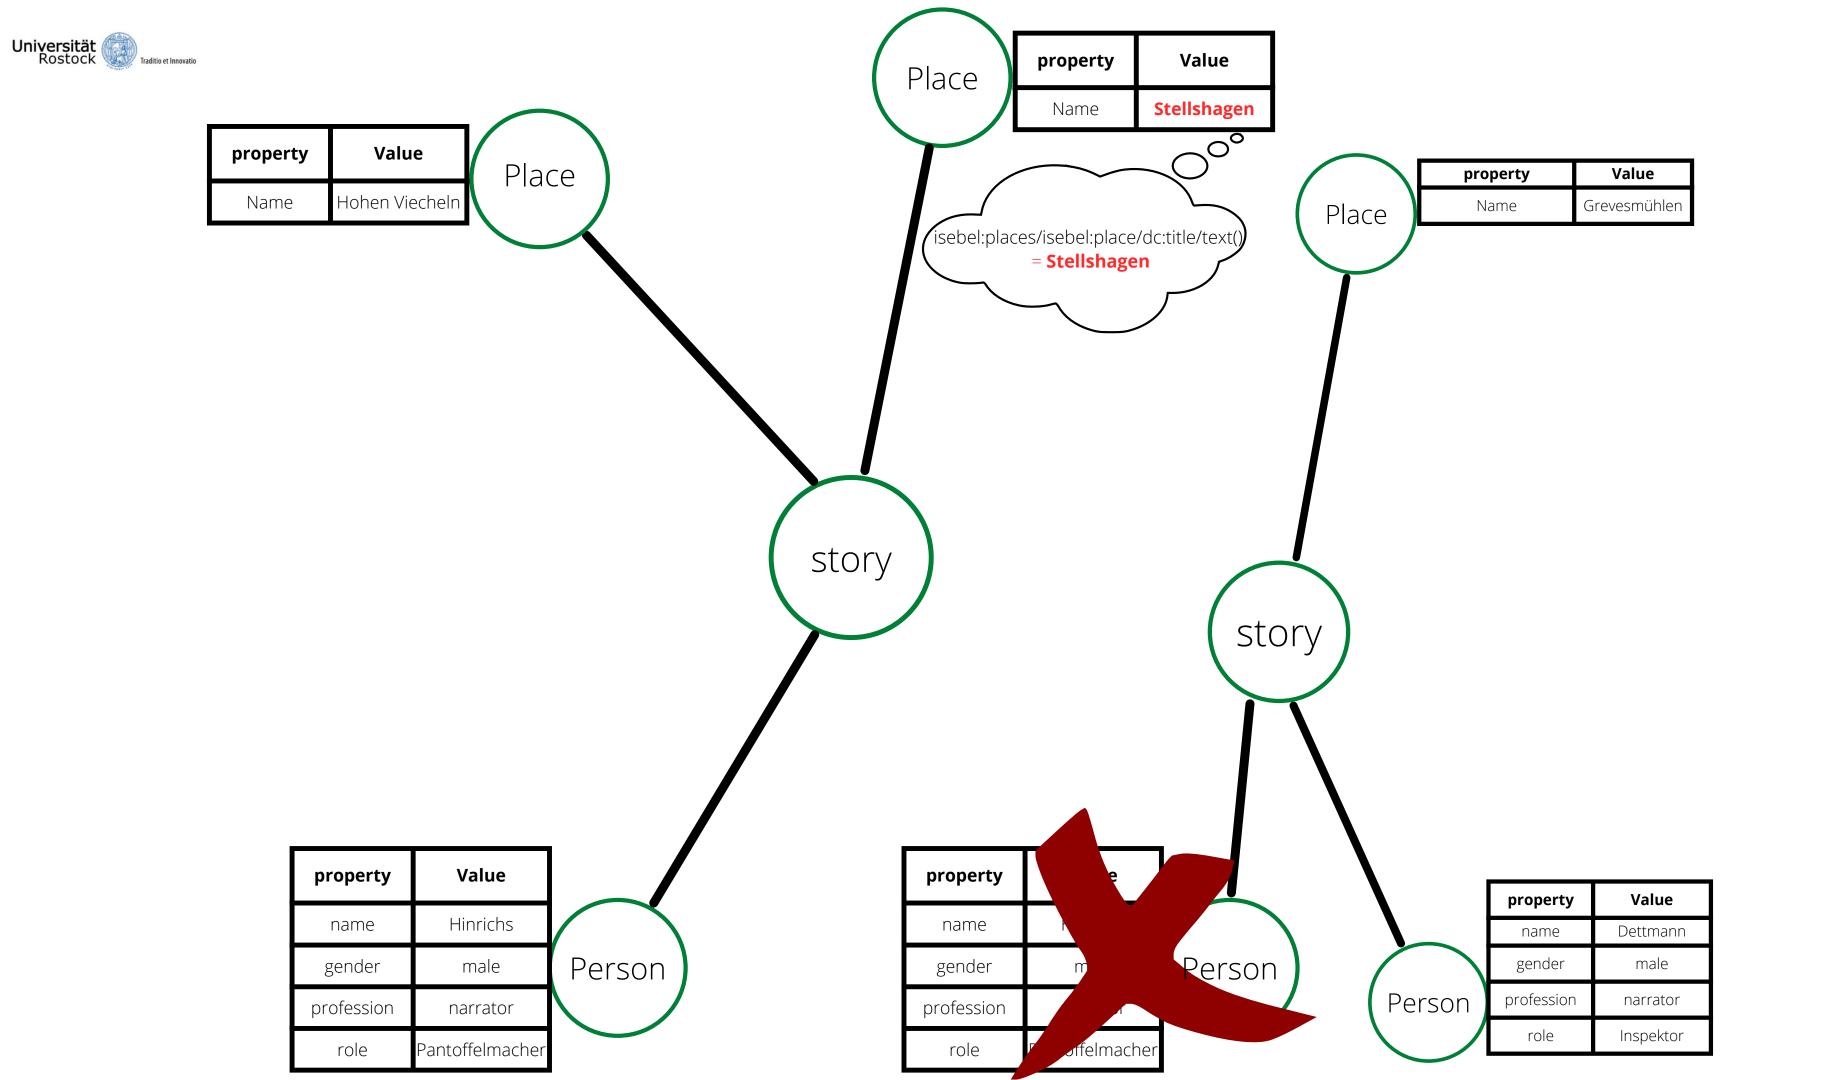


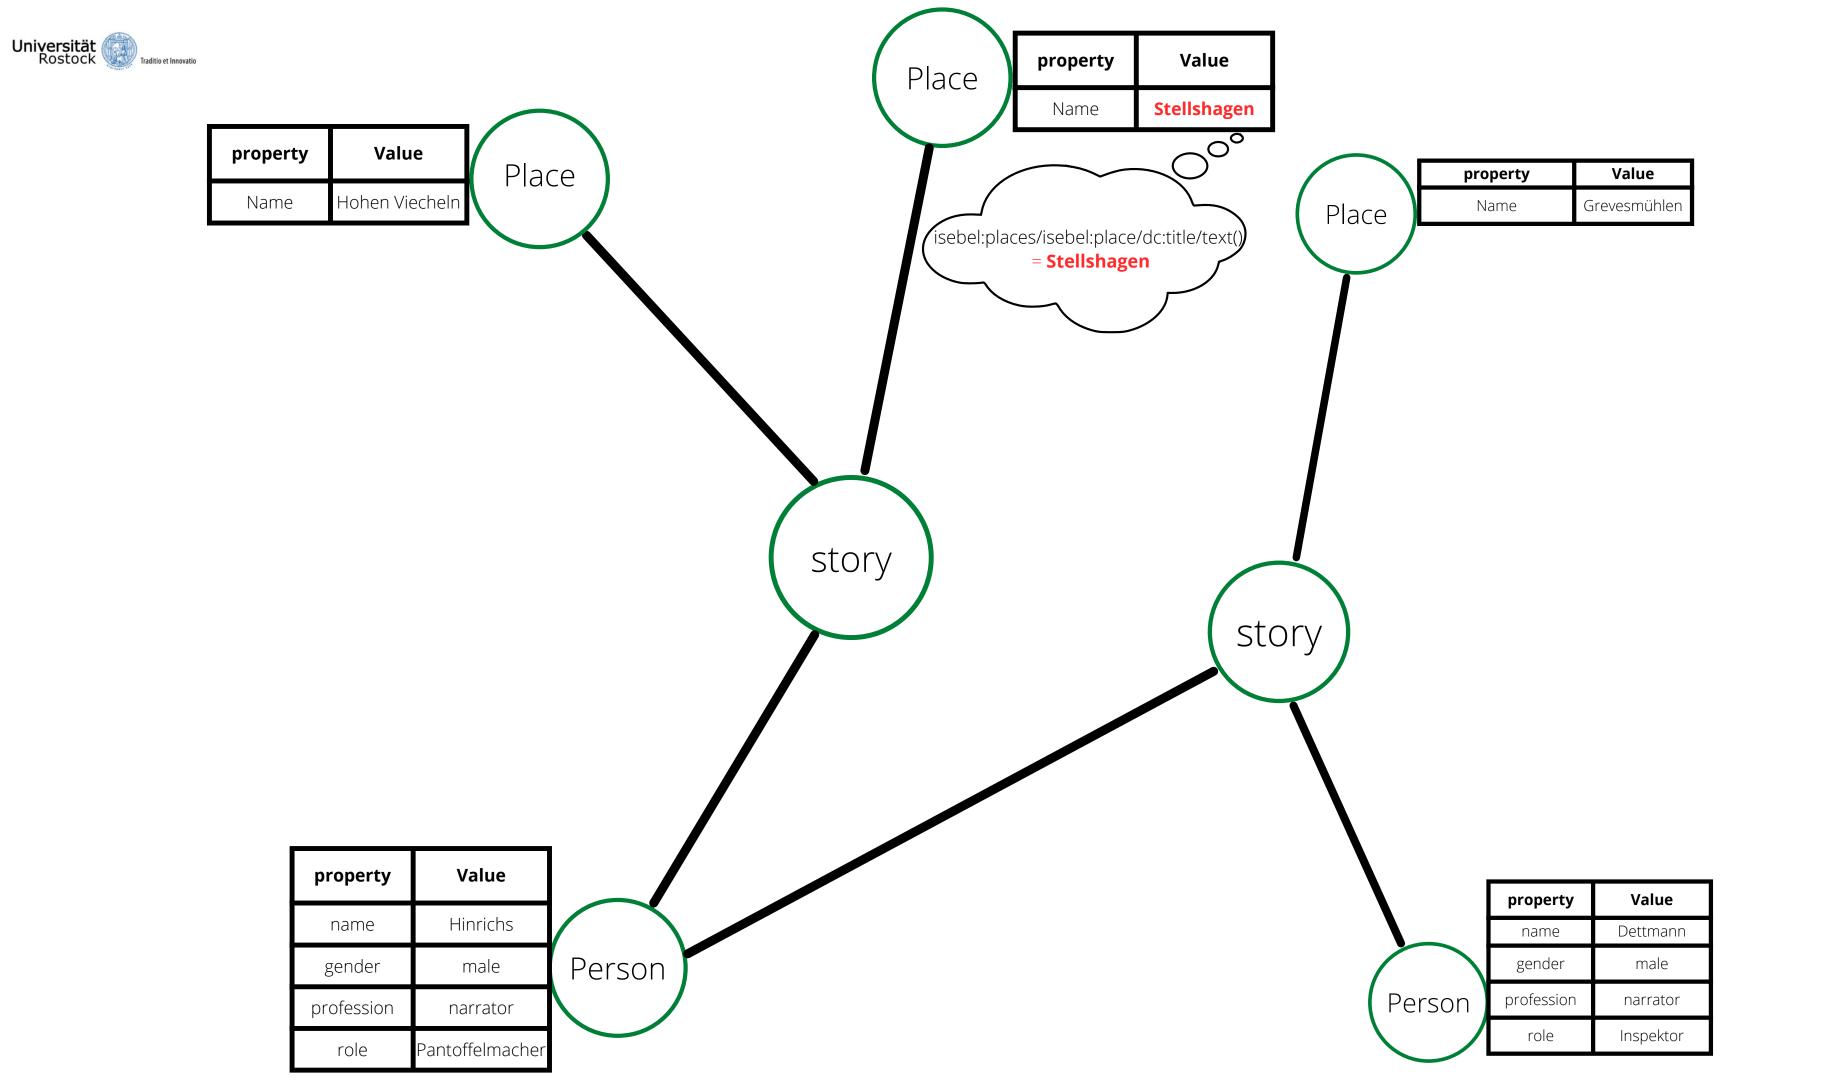














# Node replacement cases Problemdarstellung

#### Problem beim Erzeugen von Knoten:

- Verschiedene Daten/Text-Inhalte in XML-Dokumenten
- Wann wird ein neuer Knoten bzw. Kanten erzeugt?
- Wann kann ein existierender Knoten verwendet werden?
- Wann sind Knoten identisch?
- Wann wird ähnlicher Knoten verlinkt (d.h. über Kante "ähnlich" verbunden)?
- Label gibt Zugehörigkeit zu einer Klasse an/Typangabe
- Properties können in einem Teil übereinstimmen
- Schlüsseleigenschaften/Properties gegeben?
- Wenn nicht: Inwieweit stimmen Properties überein?

Fallunterscheidung notwendig!

```
▼<isebel:persons>
 ▼<isebel:person id="110001368">
    <isebel:name>Hinrichs</isebel:name>
    <isebel:gender>male</isebel:gender>
    <isebel:role>narrator</isebel:role>
    <isebel:profession>Example</isebel:profession>
  </isebel:person>
</isebel:persons>
▼<isebel:persons>
  ▼<isebel:person id="110002742">
     <isebel:name>Hinrichs</isebel:name>
     <isebel:gender>male</isebel:gender>
     <isebel:role>narrator</isebel:role>
     <isebel:profession>Pantoffelmacher</isebel:prof</pre>
   </isebel:person>
  </isebel:persons>
```



### Nodes Replacement

### Die verschiedenen Varianten

-Zwei Hauptszenarien-



- Verlinkt vorhandenen Knoten
- Ergänze evtl. weitere
   Properties

Erzeuge einen Knoten / Kanten

- Neuer Knoten wird erzeugt
- Neuer Knoten wird erzeugt
  - + kante "Is Related" verbunden mit dem Vorherigen Kanten

Beispiele folgen



N1(G1)

propertyValuenameHinrichsgendermaleprofessionnarratorrolePantoffelmacher

N2(G2)

112(UZ)	
property	Value
name	Hinrichs
gender	male
profession	narrator
role	Pantoffelmacher

Es wird kein neuer Knoten erstellt

N1(G1)

property	Value
name	Hinrichs
gender	male
profession	narrator
role	Pantoffelmacher

N2(G2)

property	Value
name	Hinrichs
gender	male
profession	narrator

Es wird kein neuer Knoten erstellt

N1(G1)

property Value

name Hinrichs

gender male

profession narrator

N2(G2)

( /	
property	Value
name	Hinrichs
role	Pantoffelmacher

Es wird kein neuer Knoten erstellt. Die Property "role=Pantoffelmacher" wird von N1(G1) zu N2(G2) übertragen

N = Konten

G = Graph

N1(G1)

,	,
property	Value
name	Hinrichs
gender	male
role	Pantoffelmacher

N2(G2)

( • _ /	
property	Value
name	Hinrichs
profession	narrator

Es wird kein neuer Knoten erstellt



N1(G1)

propertyValuenameHinrichsgendermaleprofessionnarratorrolePantoffelmacher

N2(G2)

112(UZ)	
property	Value
gender	male
profession	narrator
role	Pantoffelmacher

Es wird kein neuer Knoten erstellt

N1(G1)

property	Value
name	Hinrichs
gender	male
profession	narrator
role	Pantoffelmacher

N2(G2)

property	Value
gender	male
profession	narrator

Es wird kein neuer Knoten erstellt

N1(G1)

property Value

name Hinrichs

gender male

profession narrator

N2(G2)

1 N Z (	( /
property	Value
name	Hinrichs

Es wird kein neuer Knoten erstellt

N = Konten

G = Graph

N1(G1)

, ,	
property	Value
name	Hinrichs
gender	male

N2(G2)

property	Value
name	Hinrichs

Es wird kein neuer Knoten erstellt



N1(G1)

propertyValuenameHinrichsgendermaleprofessionnarratorrolePantoffelmacher

K2(G2)

	,
property	Value
name	Dettmann
gender	male
profession	narrator
role	Inspektor

Ein neuer Knoten wird erstellt

N1(G1)

property	Value
name	Dettmann
gender	male
profession	narrator
role	Pantoffelmacher

N2(G2)

112(02)	
property	Value
name	Hinrichs
gender	male
profession	narrator
role	Pantoffelmacher

Ein neuer Knoten wird erstellt

N1(G1)

property	Value
name	Hinrichs

N2(G2)

112(02)	
property	Value
name	Dettmann
gender	male
profession	narrator
role	Pantoffelmacher

Ein neuer Knoten wird erstellt

G = Graph

N = Konten

property	Value
name	Hinrichs
gender	male

N2(G2)

( /	
property	Value
name	Hinrichs
gender	male
profession	narrator
role	Pantoffelmacher

Kein neuer Knoten wird erstellt



N1(G1)

property Value

name Hinrichs

gender male

profession narrator

N2(G2)propertyValuenameHinrichsgendermaleprofessionnarratorroleInspektor

Kein neuer Knoten, Eigenschaften ergänzen beim alten Knoten!

N1(G1)	
property	Value
name	Hinrichs
role	Pantoffelmacher

N2(G2)	
property	Value
name	Hinrichs
gender	male
profession	narrator

Alten Knoten lassen und Eigenschaften vereinigen.

N1(G1)

(	<b>O</b> · <i>j</i>
property	Value
name	Hinrichs
profession	narrator

N2(G2)

property	Value
name	Hinrichs
profession	narrator
role	Pantoffelmacher

Kein neuer Knoten, Eigenschaften ergänzen beim alten Knoten!

N = Konten

G = Graph

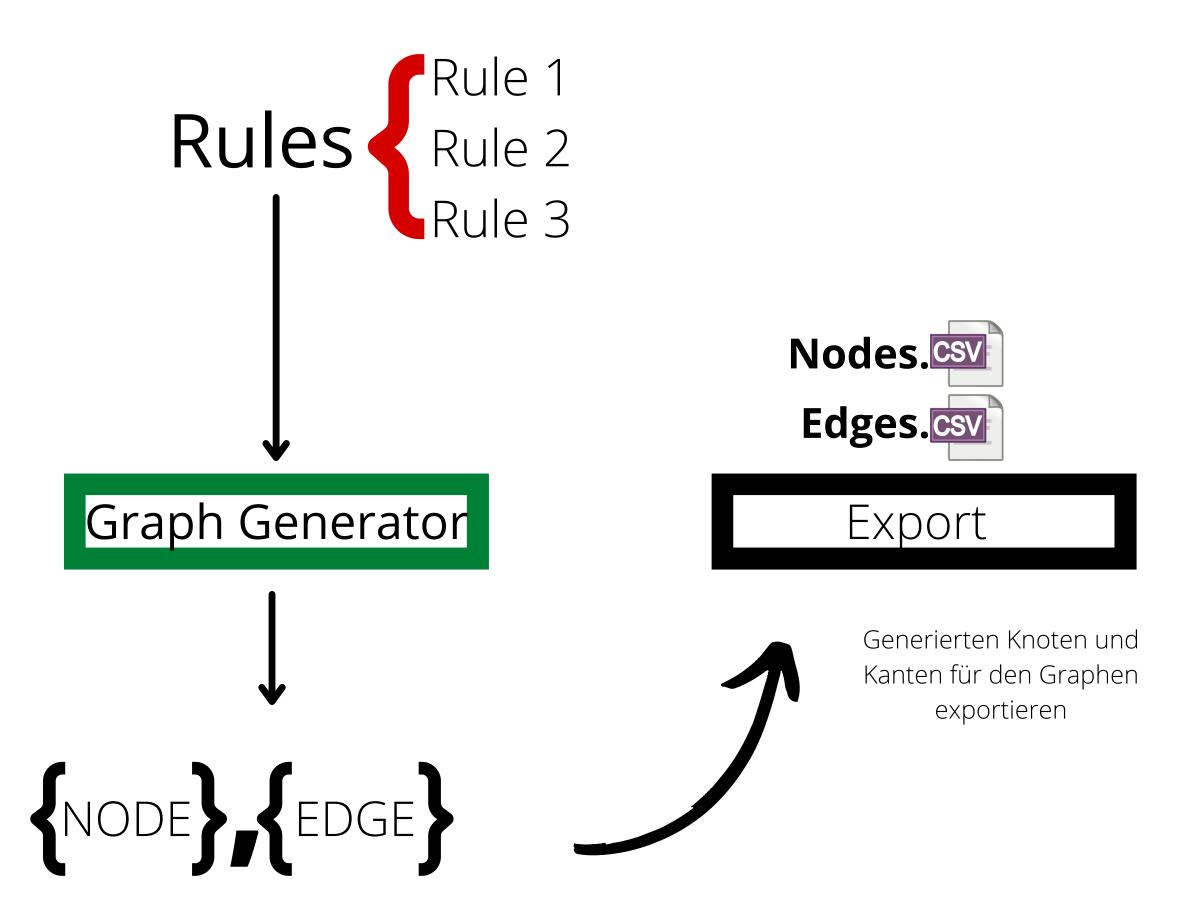
N1(G1)		ls F
property	Value	
gender	male	
profession	fession narrator	
role	Pantoffelr	macher

۱ ا ا	N2(G2)			
	property	Value		
	name	Hinrichs		
	gender	male		
	profession	narrator		
	role	Pantoffelmacher		

Neuer Knoten erzeugt, aber eine Kante "Is Related" wird da erzeugt



### Exporter





### Ergebnisse

### Beispiel für die Ausgabe als .CSV



"ID","Label","Type","Property"

"1","xmd\_s001\_000\_005.xml","story",""

"2","Person","Person","name:Hinrichs;gender:male;role:narrator;profession:Pantoffelmacher"

"3","Place","Place","name:Hohen Viecheln"

"4","Place","Place","name:Stellshagen"

"5","xmd\_s001\_000\_000\_006.xml","story",""

"6","Place","Place","name:Grevesmühlen"

# Edge. CSV

"ID","Source","Target","Label"
"1","1","2","Person"
"2","1","3","Place"
"3","1","4","Place"
"4","5","2","Person"
"5","5","6","Place"



### Beispiel-Szenarien für Graph-Generieren:

- Alle Storys von einer bestimmten Person XY
- Alle Storys, die an einem bestimmten Ort erzählt wurden (Stellshagen, Wismar...)
- Einfluss des Geschlechts des Erzählers auf die Hexen- oder Werwolf-Sagen
- Alle Storys, die in 3 Sprachen (DEU, NDS, ENG) verfügbar sind

Regelsprache Beispiel

```
// nested match example, the second match is evaluated within the context of the first
match xpath("//story") using $s {
        create node $sn label "story" {
                // properties
                content = $s.xpath("content/text()"),
                title = $s.xpath("title/text()"),
                unique (title)
        },
        match xpath(".//person[@role='narrator']") using $p {
                create node $pn label "person" {
                        // properties with optional type declaration
                        name = $p.xpath("name/text()"),
                        age = $p.xpath("age"),
                        unique (name, age),
                        // conditional assignment
                        if $p.xpath("appellation/text()") == "Mr" {
                                gender = "male" + "narrator"
                create edge $e from $sn to $pn label "narrator" {
                        alt = "story-teller"
                        /* no more properties given */
                // should warn about $p hiding earlier binding
```



### Zusammenfassung



- Konzept/Entwurf erstellt
- Folgende Teile wurden implementiert:
- Filter 🗸
- Graph-Generator 🗸
  - -Knoten
  - -Kanten
- Exporter 🗸
  - -Csv



### **Ausblick**



- Teile die nicht implementiert wurden Zeitbeschränkung:
- Wichtige Erweiterungen
  - -Die Regelsprache einbinden
- Mögliche/zukünftige Erweiterungen:
  - -Document stores JSON-Daten (Gibt es bereit Nachfolger für die Arbeit)
  - -Key-values store
  - -No-Sql Systemen
  - -Relationale Strukturen

Daraus noch Graphen erzeugen.

- Einfache Erweiterungen
- Ausgabe der generierten Graphen
  - -Gexf
  - -Graphml
  - -etc.



## Danke für eure Aufmerksamkeit 🏇 Wenn ihr Fragen habt, könnt ihr diese jetzt stellen

